

МАГІСТЕРСЬКА КВАЛІФІКАЦІЙНА РОБОТА

# Дослідження моделей векторних ембеддінгів для семантичного пошуку текстових даних у корпоративних базах знань

Виконав: **Нестеренко Віталій Вячеславович**

Група: **ІПЗм-24-1**

Науковий керівник:

**к.т.н., доцент Русакова Наталія Євгенівна**

**15 травня 2026**

*Харків*



ХАРКІВСЬКИЙ  
НАЦІОНАЛЬНИЙ  
УНІВЕРСИТЕТ  
РАДІОЕЛЕКТРОНІКИ



МІНІСТЕРСТВО  
ОСВІТИ І НАУКИ  
УКРАЇНИ



## ● Актуальність, мета та задачі дослідження



**МЕТА:** визначення доцільності застосування сучасних моделей векторних ембедінгів для підвищення ефективності семантичного пошуку текстових документів у корпоративних базах знань шляхом порівняльного експериментального дослідження.

### ОБ'ЄКТ

процеси формування та використання векторних подань текстових даних у системах семантичного пошуку

### ПРЕДМЕТ

моделі векторних ембедінгів для семантичного пошуку у корпоративних базах знань

### ЗАДАЧІ ДОСЛІДЖЕННЯ

1

Аналіз предметної галузі

2

Огляд embedding-моделей

3

Формування benchmark dataset

4

Реалізація системи пошуку

5

Оцінка якості моделей

6

Вибір оптимальної моделі

## ● Огляд літератури: еволюція embedding-моделей



**Дослідницька прогалина:** відсутність порівняльних досліджень embedding-моделей на україномовних доменно-специфічних колекціях. **Опрацьовано 29 наукових джерел** (Lewis 2020 — RAG, Robertson 2009 — BM25, Thakur 2021 — BEIR, Muennighoff 2023 — MTEB).



Хронологічний охоплуваний період: **2013 – 2025** · статистичні → контекстні → багатофункціональні · **12+ років еволюції**

# Постановка задачі дослідження

## ПРОБЛЕМА

Недостатньо просто застосувати сучасну embedding-модель — необхідно обґрунтовано визначити модель, що забезпечує оптимальний баланс між:

- якість семантичного пошуку
- швидкодія на CPU/GPU
- вимоги до пам'яті та ресурсів
- мовна підтримка
- тип колекції документів

## ОЧІКУВАНІ РЕЗУЛЬТАТИ

- 1 Реалізована система семантичного пошуку (PDF / DOCX / TXT / MD)
- 2 Власноруч сформований UA benchmark dataset (3 домени)
- 3 Кількісне порівняння 4 embedding-моделей + BM25 baseline
- 4 Багатокритеріальний вибір моделі (Парето + лінійна згортка)
- 5 Обґрунтовані практичні рекомендації для впровадження

# Сучасні моделі векторних ембедінгів

## BGE-M3

BAAI

параметри **568M**  
 max tokenів **8 192**  
 архітектура **Encoder**

*dense + sparse + multi-vector*

## E5-base

intfloat

параметри **278M**  
 max tokenів **512**  
 архітектура **Encoder (ML-E5)**

*префікси query: / passage:*

## nomic-embed v1.5

Nomic AI

параметри **137M**  
 max tokenів **8 192**  
 архітектура **Encoder**

*Matryoshka representations*


## Qwen3-Embed-0.6B

Alibaba


параметри **596M**  
 max tokenів **32 768**  
 архітектура **Decoder (LLM)**

*instruction-aware*

### ПАРАМЕТРИ МОДЕЛІ



### МАХ ТОКЕНІВ (ЛОГАРИФМІЧНА ШКАЛА)



## ● Методологія дослідження

### МЕТРИКИ ОЦІНЮВАННЯ RETRIEVAL-ЯКОСТІ

**nDCG@10**

якість ранжування  
(основна)

**MRR@10**

позиція першого  
релевантного

**R@10**

повнота  
пошуку

**P@10**

точність  
видачі

**ms/q**

час відповіді  
(швидкодія)

### МЕТОДИ АНАЛІЗУ



**Bootstrap CI**

95% довірчий інтервал для nDCG@10

*n = 2 000 повторень з повторами*



**Парето-домінування**

Виявлення Парето-оптимальних  
альтернатив  
*у багатокритеріальному просторі*



**Лінійна адитивна  
згортка**

Інтегральна оцінка  $U(a_i)$

*з ваговими коефіцієнтами критеріїв*

## Метрики оцінювання retrieval-якості

 **$nDCG@k$** 

0 ... 1, ↑

Нормалізована якість ранжування

$$DCG@k / IDC@k$$

 $DCG@k = \sum_i (2^{\text{rel}_i} - 1) / \log_2(i+1)$  ;

 $IDC@k$  — DCG ідеального ранжування

 **$MRR$** 

0 ... 1, ↑

Mean Reciprocal Rank

$$(1 / |Q|) \cdot \sum (1 / \text{rank} q)$$

Середнє по запитах:  $1 / (\text{позиція першого релевантного документа у видачі})$

 **$Recall@k$** 

0 ... 1, ↑

Повнота пошуку

$$|Rel \cap Retrieved| / |Rel|$$

Частка знайдених релевантних документів серед усіх релевантних у колекції

 **$P@k$** 

0 ... 1, ↑

Precision@k

$$|Rel_k| / k$$

Частка релевантних документів серед перших k результатів видачі

## Багатокритеріальний вибір моделі (МКВ)

1

### Парето-домінування

$$P = \{a_i \in A \mid \nexists ak \in A : ak \succ a_i\}$$

Виявлення альтернатив, які не домінуються жодною іншою за усіма критеріями одночасно

2

### Нормалізація шкал

$$y_{ij} = (x_{ij} - \min x_j) / (\max x_j - \min x_j)$$

Приведення критеріїв до єдиної шкали [0; 1] з врахуванням напрямку оптимізації

3

### Лінійна адитивна згортка


$$U(a_i) = \sum_j w_j \cdot y_{ij}, \text{ де } \sum_j w_j = 1$$

Інтегральна оцінка корисності з ваговими коефіцієнтами критеріїв

### ПРОФІЛІ ВАГ КРИТЕРІЇВ ЗА ДОМЕНАМИ (k=10)

| Домен     | nDCG | MRR  | Recall | P    | Latency |
|-----------|------|------|--------|------|---------|
| Технічний | 0.30 | 0.20 | 0.25   | 0.05 | 0.20    |
| Юридичний | 0.30 | 0.30 | 0.20   | 0.10 | 0.10    |
| Медичний  | 0.25 | 0.15 | 0.35   | 0.10 | 0.15    |

### РОЗПОДІЛ ВАГ ЗА ДОМЕНАМИ





## Архітектура системи семантичного пошуку



Запит користувача



Flask Web UI

Основні компоненти: `build_index.py` · `evaluate_benchmark.py` · `embedding_models.py` · `run_all_benchmarks.py` · `app.py`

## ● Програмне забезпечення та технології



### ML / EMBEDDING

- Python 3.11
- sentence-transformers
- transformers (HF)
- PyTorch (CPU)
- trust\_remote\_code
- Cambria Math



### RETRIEVAL / DATA

- FAISS (IndexFlatIP)
- rank\_bm25 (Okapi)
- L2-нормалізація
- Чанкінг (~600 слів)
- PDF / DOCX / TXT / MD
- JSONL (chunks, qrels)




### WEB / EVAL / ANALYSIS

- Flask (Python)
- NumPy, scikit-learn
- Bootstrap CI (n=2000)
- Pareto + лінійна згортка
- Власний benchmark harness
- Git + GitHub

## ● Benchmark dataset: українськомовні доменні колекції

Власноруч сформований **domain-specific українськомовний benchmark**: 3 домени · 32 документи · 300 запитів · qrels сформовано вручну



### Технічний

*програмна інженерія, ML, RAG, аномалії, 3D-друк, лідарні системи*

10

документи

100

запити



### Юридичний

*кодекси, нормативно-правові акти, законодавство*

13

документи

100

запити



### Медичний

*клінічні протоколи, медичні рекомендації*

9

документи

100

запити

## ● Приклади benchmark-запитів



### Технічний

- 1 «виявлення аномалій у фінансових транзакціях»
- 2 «комбінація Autoencoder та Isolation Forest для fraud detection»
- 3 «прогноз відтоку клієнтів (churn prediction)»
- 4 «когортний аналіз для сегментації клієнтів»
- 5 «етичні питання використання персональних даних»



### Юридичний

- 1 «що таке цивільна дієздатність фізичної особи»
- 2 «з якого віку настає повна цивільна дієздатність»
- 3 «підстави обмеження цивільної дієздатності судом»
- 4 «поняття юридичної особи та порядок її реєстрації»
- 5 «що входить до складу спадщини»




### Медичний

- 1 «що таке серцево-судинна система»
- 2 «будова та функції серця людини»
- 3 «що таке артеріальний тиск і як він регулюється»
- 4 «велике і мале коло кровообігу — відмінності»
- 5 «будова дихальної системи людини»

## Результати експерименту: nDCG@10

nDCG@10 ПО ДОМЕНАХ (вище — краще)



СЕРЕДНІЙ nDCG@10

|    |         |        |
|----|---------|--------|
| #1 | BGE-M3  | 0.4708 |
| #2 | Qwen3   | 0.4385 |
| #3 | E5-base | 0.4199 |
| #4 | BM25    | 0.3319 |
| #5 | nomic   | 0.2128 |

## BOOTSTRAP 95% CI





n = 2 000 · Технічний домен:

BGE-M3: [0.606 ; 0.737]

BM25: [0.431 ; 0.541]

→ інтервали не перетинаються —  
статистично значуща перевага  
семантичного пошуку над лексичним

## Деталізовані метрики за доменами

**nDCG@10****MRR@10****Recall@10****P@10**

## Багатокритеріальний вибір моделі: результати

### ПАРЕТО-ОПТИМАЛЬНА МНОЖИНА

$$P = \{ BGE-M3, E5-base, BM25 \}$$

З 5 альтернатив не домінуються жодною іншою за усіма критеріями одночасно

#### BGE-M3

лідер у 3 доменах за nDCG, MRR, Recall

#### E5-base

швидка альтернатива, ~70 мс vs ~228 мс у BGE-M3


#### Qwen3

лідер на юридичному (nDCG=0.320), ~2× повільніший

#### nomic


найслабші результати; в окремих доменах поступається BM25

### ІНТЕГРАЛЬНА ОЦІНКА $U(a_i)$ ПО ДОМЕНАХ



## Аналіз: якість пошуку vs швидкодія

ТЕХНІЧНИЙ ДОМЕН · nDCG@10 vs ms / запит



### КЛЮЧОВІ ВИСНОВКИ

Парето-оптимальна · лідер якості

#### BGE-M3

nDCG = 0.672 · ~228 мс · основний вибір

Парето-оптимальна · sweet spot

#### E5-base

~70 мс · 3× швидше за BGE-M3

Парето-оптимальна · baseline

#### BM25

<3 мс · стеля якості ~0.49 nDCG

Спеціалізована · лідер на Legal

#### Qwen3

0.320 на Legal · на Tech домінується

Не рекомендується · домінується

#### nomic

поступається BM25 за якістю



## ● Апробація результатів дослідження

1

КОНФЕРЕНЦІЯ

2026

### «Innovative Research in Science and Economy»

*2-я Міжнародна науково-практична конференція*

**Стаття:** «Порівняльний аналіз ефективності моделей векторних ембеддінгів для задач семантичного пошуку в корпоративних базах знань»

**Внесок:** Представлено benchmark-методологію та порівняння 4 моделей у трьох доменних колекціях; обґрунтовано перевагу BGE-M3 над класичним BM25.

2

КОНФЕРЕНЦІЯ

2026

### «Радіoeлектроніка та молодь у XXI столітті»

*30-й Міжнародний молодіжний форум, ХНУРЕ*

**Тези:** «Підвищення якості семантичного пошуку в базах знань із використанням векторних подань»

**Внесок:** Подано підхід до підвищення якості retrieval у корпоративних базах знань на основі контрастивно-навчених embedding-моделей.

**ЗАГАЛОМ:** 2 наукові праці · 2 виступи на міжнародних конференціях · у співавторстві з науковим керівником · ХНУРЕ, 2026

## ● Підсумки та практичні рекомендації



Обґрунтовано доцільність застосування embedding-моделей для семантичного пошуку у корпоративних базах знань



### BGE-M3

Основна модель для впровадження

Найкраща якість, стабільність у різних доменах



### E5-base

Швидка альтернатива

Прийнятна якість + ~3x швидше за BGE-M3



### Qwen3

Лідер на юридичному домені

Найвища nDCG@10 на Legal (0.320), ~2x повільніший



### BM25

Конкурентний baseline

Залишається сильним у певних доменах

*Дякую за увагу!*